


딥러닝 모델을 활용한 콘크리트 표면 균열 감지

딥러닝기반데이터분석 과제II

Dataset Overview: Surface Crack Detection Dataset

목적: 토목 구조물의 주요 결함인 콘크리트 표면의 균열을 감지하여 건물의 상태를 평가하고 구조적 안전성을 확보하기 위함





- 구조
 - 총 40,000개의 이미지
 - 각 클래스(positive/negative)에 20,000개 이미지 포함
 - 이미지 크기: 227 x 227
- 특징
 - RGB 채널을 가짐
 - 다양한 표면 마감과 조명 조건에서 촬영된 고해상도 이미지
- 출처
 - <https://www.kaggle.com/datasets/arunrk7/surface-crack-detection>
 - Zhang et al. (2016) 연구에서 제안된 방법을 통해 생성된 고해상도 이미지에서 추출



학습 시간을 줄이기 위해서 각 클래스별로 1,000개씩 총 2,000개의 데이터로 학습 진행

이진 분류용
레이어 수정 모델Conv Layer
& 이진 분류용 레이어
수정 모델1. Fine-Tuning 및
학습 설정

- 이진 분류용 레이어 수정 모델
 - 사전 학습 가중치 사용: ImageNet 기반 사전 학습
 - 출력 레이어 수정: 이진 분류를 위한 최종 레이어 조정
- Conv Layer 및 이진 분류용 레이어 수정 모델
 - 첫 번째 Convolution Layer를 kernel_size=3, stride=1, padding=1로 수정하여 세부 특징에 집중
- 학습 파라미터: 배치 크기: 64, 에포크: 10, 학습률: 0.001
- 데이터 분할: 학습(70%) / 검증 (15%) / 테스트(15%)



2. 성능 비교

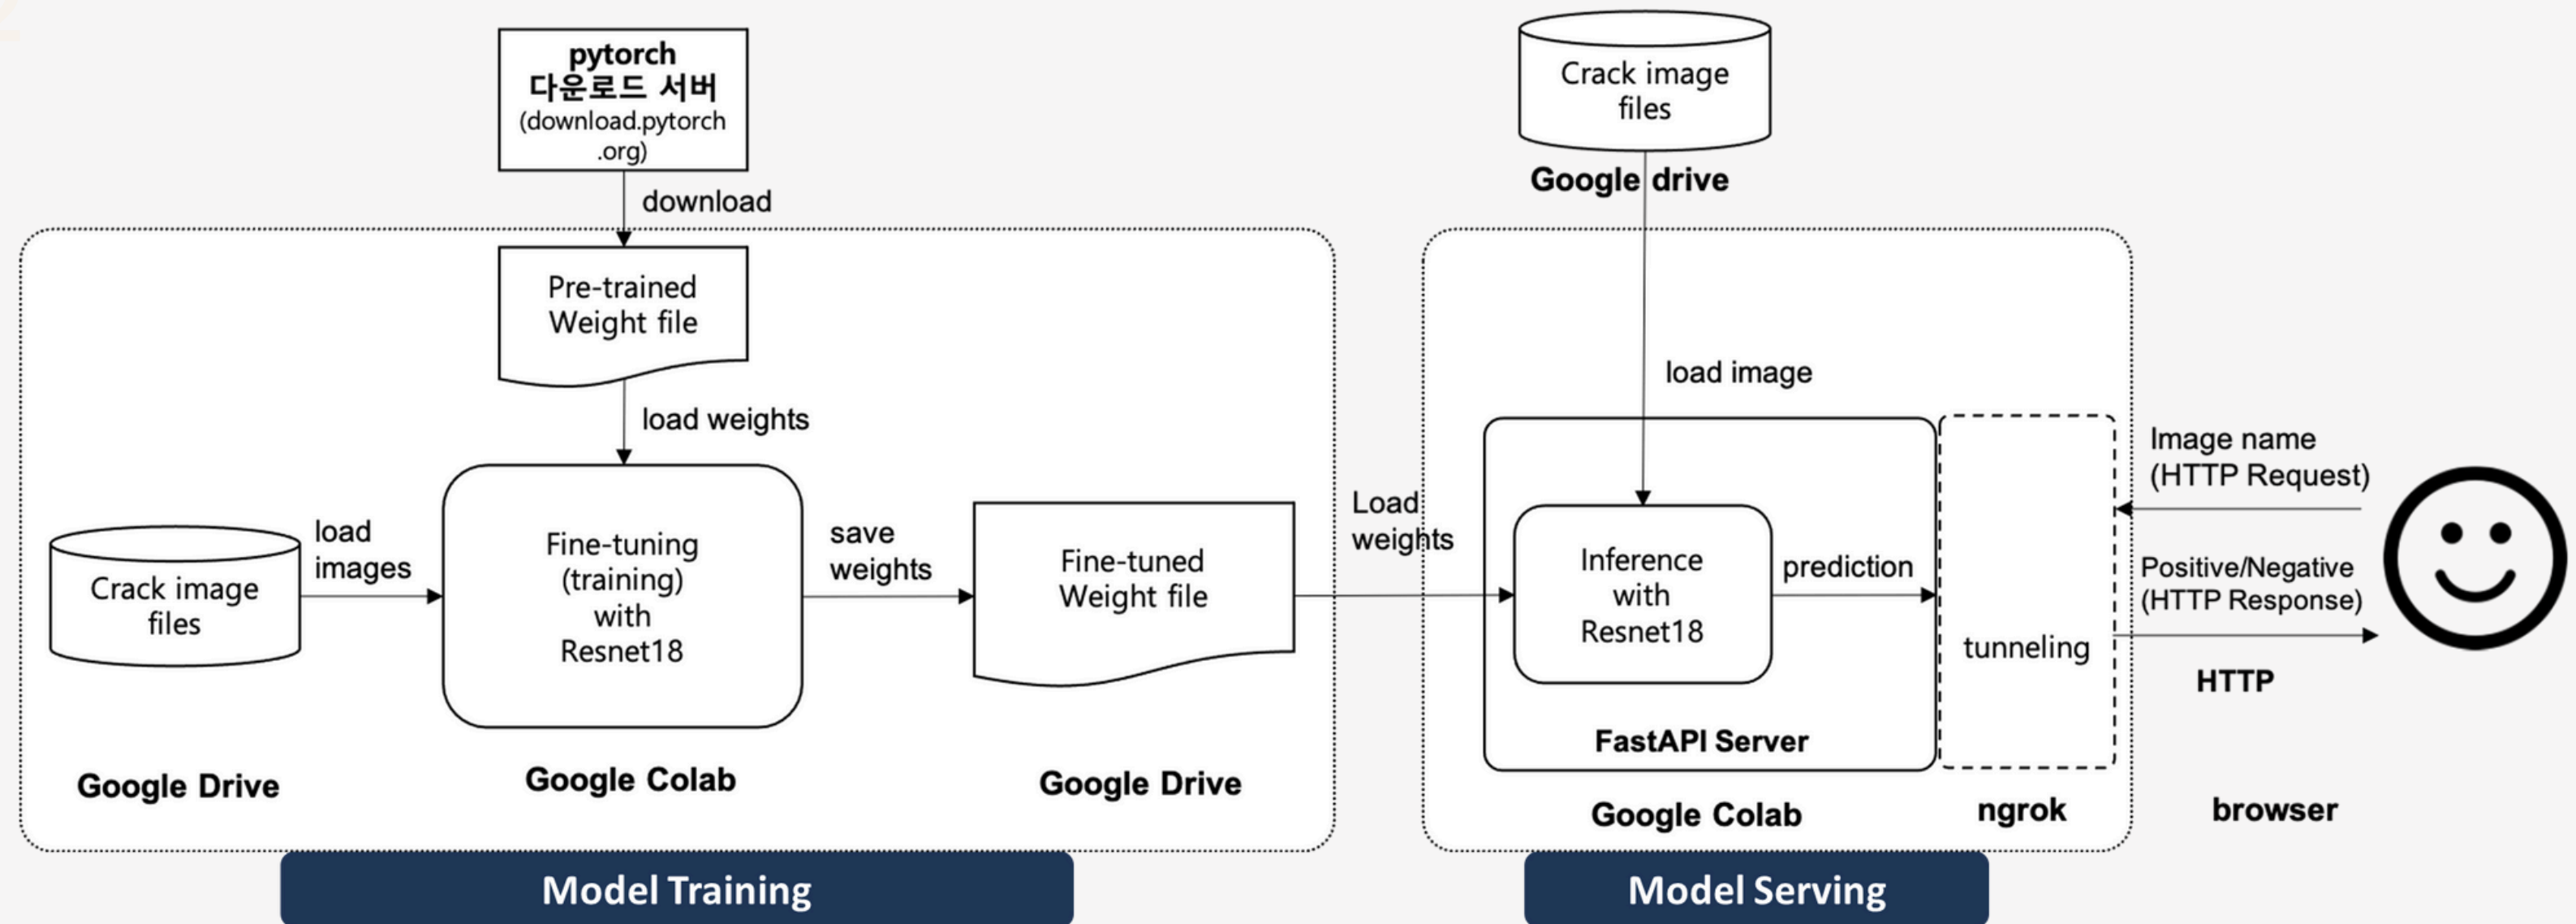
- 이진 분류용 레이어 수정 모델
 - 최종 검증 정확도: 약 99%
 - 학습과 검증 손실이 안정적으로 감소하며 과적합 없이 높은 정확도 유지

- Conv Layer 및 이진 분류용 레이어 수정 모델
 - 과적합 발생 전 검증 정확도: 최고 약 99%
 - 과적합 발생 후 최종 검증 정확도: 약 94%로 급락
 - 학습 초기 성능은 뛰어나지만, 8 에폭 이후 검증 손실 급등과 정확도 감소로 과적합 발생
 - 향후 개선사항: Early Stopping 도입, Regularization 기법 사용

3. 최종 결론

Conv Layer & 이진 분류용 레이어 수정 모델이 학습 초기 빠르게 성능이 향상되었으나, **과적합 문제로** 최종 일반화 성능은 낮아짐. 기존의 이진 분류용 레이어 수정 모델이 더 **안정적인 성능**을 보여줌.

ResNet18 모델 서빙 방법 (FastAPI 활용)



1. 모델 서빙 구조

- 구성 요소: Google Drive, Google Colab, FastAPI

2. 모델 서빙 과정

- 파인튜닝 모델 가중치 로드
- 이미지 파일 로드
- 예측 및 응답
 - ResNet18 모델을 통해 Crack 여부를 예측 (P/N)
 - 예측 결과를 사용자에게 HTTP 응답으로 반환

3. FastAPI 코드 주요 내용

- /imageai 엔드포인트
 - 이미지 파일과 이름을 HTTP 요청으로 받아, 전처리 후 예측
 - 모델이 예측한 결과를 JSON 형태로 반환
- 사용자 요청 흐름
 - 구글 드라이브의 이미지 이름 전달 -> FastAPI 서버 예측 -> P/N 결과 반환